

合肥大學

硕士学位论文（设计）

开 题 报 告 书

题　　目　基于多智能体强化学习的分层联邦学习激励机制研究

姓　　名　汪军　学　号　24085404012

学　　院　人工智能与大数据学院　专　业　电子信息

指导教师　职　称　艾兵　职

行业导师（专 硕）　熊科　职称（职 务）高 级 工 程 师

2025 年　11月

题目

基于多智能体强化学习的分层联邦学习激励机制研究

题目来源

国家自然科学基金项目

一、选题依据

1.选题的意义:

随着物联网(IoT)与分布式人工智能的飞速演进，如何在严守数据隐私[1]边界的前提下，实现海量异构设备间的高效协同训练，已成为下一代智能系统落地的核心瓶颈。分层联邦学习(Hierarchical Federated Learning) 架构因其优异的可扩展性而备受关注，但在这些复杂的多层级系统中，参与者的自利性行为和系统环境的高度异构性，使得传统的资源调度和激励机制[2]难以有效对。因此，基于分层联邦学习的斯塔克伯格(Stackelberg)博弈激励机制设计和多智能体深度强化学习(Multi-Agent Reinforcement Learning) [3]研究具有重要的学术意义和实践价值。特别是在包含云、边、端三层架构的大规模分布式场景中，如何设计一种能够自适应环境动态、协同优化多方利益的机制，是一个亟待解决的挑战。

本研究聚焦分层联邦学习在实际落地中的三大核心挑战——“多层级协同缺失”、“数据价值挖掘不足”与“动态适配能力薄弱”，通过理论建模与算法设计的深度融合，开展了系统性创新研究。主要研究内容如下:

第一，针对“多层级协同缺失”问题，构建三层 Stackelberg博弈模型，填补传统双层架构的逻辑缺口。现有激励机制研究虽依托分层联邦学习的物理架构，但大多将簇头简化为无决策能力的数据中继节点，仍采用“云-端”直连的双层博弈建模，忽略了簇头作为独立利益主体的自利性诉求与中间协调价值。这种简化导致模型无法真实刻画层级系统的决策逻辑，难以实现全局利益与局部利益的协同优化。本文创新性地赋予簇头“子领导者”地位，构建“云中心-簇头-工作单元”三层的 Stackelberg博弈模型，通过明确各层级的策略空间、效用函数与决策顺序，精准描述“领导者-中层协调者-底层跟随者”的互动关系，为全链路利益协同提供严谨的数学建模支撑。

第二，针对 “数据价值挖掘不足” 问题，建立面向动态权衡的参与者选择机制，解决异构环境下的资源供需错配难题。在海量异构物联网设备中，传统

随机选择或单一指标选择策略，往往难以剔除数据分布极端非独立同分布、能效低下的低质量设备，造成通信带宽与计算资源的极大浪费。本文设计了一种面向动态权衡的智能参与者选择机制，区别于传统 “后验式淘汰” 模式，创新性地引入 “数据分布熵” 作为核心价值量度，结合设备剩余能量与数据规模构建三维评估体系。通过在每轮训练启动前筛选形成高质量 “工作组”，提前过滤低价值参与方，解决异构环境下资源供需错配的问题，通过高质量数据输入提升联邦学习的模型收敛效率与泛化性能。

第三，针对“动态适配薄弱”问题，提出分层多智能体近端策略优化算法，实现复杂博弈均衡的自适应求解。边缘网络环境的时变性如设备退出与参与者信息的不完全性，导致传统静态凸优化或启发式算法[5]难以实时求解复杂的三层博弈均衡。本文将博弈均衡的寻优过程转化为智能体与环境的交互学习过程，通过引入多智能体强化学习框架，设计适配分层博弈逻辑的 HG-MAPPO 算法。该算法突破了传统数值方法对完全信息的依赖，通过“集中式评估+分布式决策”的架构，实现资源分配与激励策略的自动化决策，为动态异构场景下分层联邦学习的落地应用提供了可行的技术路径。

1.2 国内外研究概况、水平和发展趋势

国内在联邦学习（FL）激励机制研究中，已覆盖契约、拍卖、博弈三大类型，但与多智能体强化学习的深度融合不足，尤其在多层级智能体协同调控、动态策略适配等方向存在明显缺口。冯子涵在联邦学习安全契约激励研究中，提出基于契约理论的深度强化学习算法[5]，针对弱不完全信息场景设计自我揭示型契约，通过“任务发布者 - 本地模型所有者”的双层契约匹配，解决参与者类型隐瞒问题。该研究虽引入强化学习实现动态契约调整，但采用扁平架构：契约设计仅由中心端单向主导，未设置中间层智能体承担“契约拆分-局部适配-反馈传递”功能，且未通过多智能体协同优化契约条款的差异化适配能力。郭英芸[6]提出中心端主导的反向多维拍卖框架，通过参与者在数据质量、计算能力、通信开销等多维度的竞价提交，结合中心端的多目标优化择优算法，实现联邦学习任务与终端资源的精准匹配；同时通过多维竞价定价机制，平衡中心端激励成本、终端参与意愿及任务完成质量，保障联邦学习协同训练的高效推进。但采用集中式决策，无中间层分片处理，未引入强化学习优化策略，终端静态报价难适配动态异构场

景，灵活性不足。常姗[7]课题组的研究中，将联邦学习建模为多次单阶段博弈，通过合作夏普利值评估参与者贡献，解决非独立同分布数据下的负收益问题。该机制虽引入博弈思想，但采用“中心 - 终端”扁平博弈结构：激励分配仅依赖中心端单向计算，未赋予中间层智能体簇内博弈协调权限，且未通过多智能体强化学习优化博弈策略，当簇内设备数据价值差异显著时，夏普利值分配的激励公平性偏差达较大，无法像博弈那样实现“全局公平 - 簇内均衡”的双重目标。

国外在 FL 与 MADRL 融合的激励机制研究中，三类激励机制均有技术积累，但在多层级多智能体协同、动态策略适配等关键方向仍有完善空间，为后续研究提供了改进方向。Xavier Tan[8]针对传统契约理论在 FL 中静态固定、难以适配动态变化的局限，提出可重协商契约激励机制，联合考虑数据所有者的数据量、迭代次数、计算与通信来设计契约通过贝叶斯更新实时调整锲约条款，但重协商需满足严格条件，且未适配设备动态进出场景。Kanoria[9] 提出基于动态保留价的拍卖激励框架，通过多智能体强化学习建模重复拍卖中的 bid 学习过程，解决传统固定价机制下参与方贡献意愿不足的问题，实现激励成本与模型收益的动态平衡，但该机制仅聚焦单资源分配场景，未考虑多资源耦合调度需求，且未适配联邦学习中终端设备的高移动性特征。Mousavi[10]构建深度强化学习驱动的联邦学习激励模型，通过多智能体协作优化参与方的贡献分配策略，有效降低了分布式训练中的免费搭车行为，提升了模型收敛效率，但模型假设参与方数据呈独立同分布（IID），对非 IID 数据场景的鲁棒性不足，且未纳入通信能耗、隐私保护成本等实际约束因素。

存在问题：

联邦学习激励机制[11]与多智能体强化学习融合领域的核心难题，集中体现在“多层级协同缺失”“动态适配薄弱”“数据价值挖掘不足”三个维度。这些问题导致传统方案在大规模、高动态、高异构场景中，普遍面临可扩展性差、鲁棒性不足、资源利用率低的困境，难以满足实际应用需求，DynaPart-HFL 通过创新架构与策略设计，为这些问题提供了系统性解决方案。逻辑框架如下：

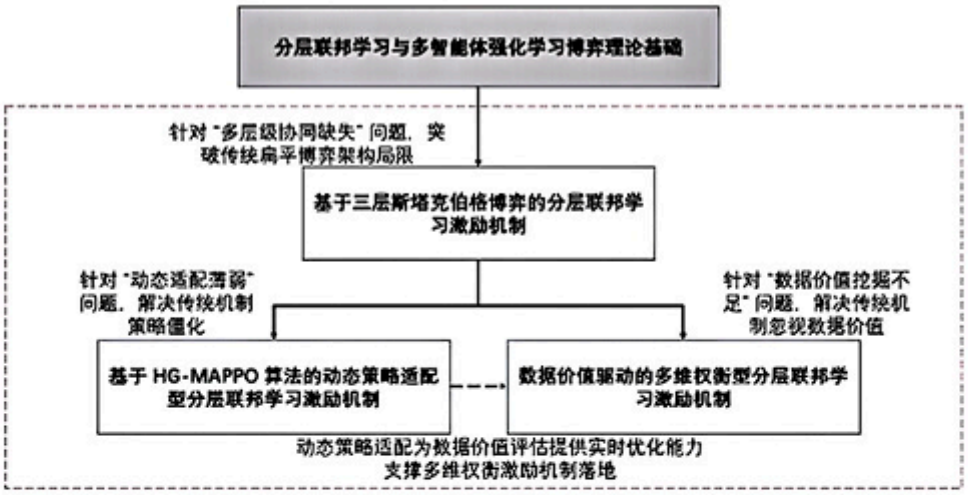


图 1 论文研究逻辑结构图

- **多层级智能体协同机制缺失，系统可扩展性受限问题**

当前多数方案未构建全局与局部联动的多层级协同体系，要么采用中心-终端扁平架构，要么仅进行简单的两阶段决策拆分 。一方面，缺乏中间层的“局部协调- 息传递”功能，中心端需直接处理所有终端设备的决策请求，计算与通信复杂度随设备规模显著增长，无法支撑大规模部署；另一方面，各层级决策缺乏动态联动，全局策略无法根据局部设备状态（如能量衰减、数据价值变化）灵活调整[12]，局部反馈也无法及时反哺全局优化，易出现“全局最优与局部最优脱节”的矛盾，导致系统整体效用下降。为解决这一问题 DynaPart-HFL 紧扣**“三层智能体 + 三层博弈”**核心框架，构建“云中心（CC）-簇（CHs）-工作单元（WUs）”三层智能体协同体系。CC 智能体作为全局决策层，负责全局激励预算分配、资源配额调控与全局状态感知，为三层博弈提供顶层约束；CHs 智能体作为中间协调层，承担簇内博弈协调、契约拆分与局部策略优化，既是 CC 全局策略的落地执行者，也是 WUs 局部反馈的汇总传递者，有效分散中心端决策压力；WUs 智能体作为本地执行层，聚焦本地参与意愿决策与执行反馈传递，为簇内博弈提供参与主体。通过**HG-MAPPO 算法**实现三层智能体策略动态协同，CC 将全局博弈目标拆解为簇级子目标，CHs 结合簇内设备状态优化子博弈策略，WUs 通过实时反馈调整参与行为，形成 “全局-簇级-本地 闭环决策链，显著提升系统可扩展性，缓解传统架构的规模瓶颈。

- **数据异质性与激励决策协同不足，数据价值挖掘不充分问题**

当前研究的激励机制[13]与参与者选择，多聚焦设备硬件能力（如算力、能量、竞价成本），忽视数据价值（如数据多样性、样本量、类别完整性）的核心影响 。一方面，导致高数据价值但硬件能力一般的设备因未获合理激励而退出训练，造成数据资源浪费；另一方面，未构建“数据价值 - 激励强度”动态匹配机制，无法根据每轮训练中设备的实际数据贡献调整激励策略，难以充分激发高价值设备的持续参与意愿，最终影响全局模型泛化性。为解决这一问题，DynaPart-HFL 围绕“数据价值驱动三层博弈”设计，**构建“多维度价值评估-动态激励匹配”**体系。一是在 CHs 智能体中嵌入数据价值评估模块，作为簇内博弈的核心依据，通过计算数据多样性熵值、样本类别完整性与模型贡献度，量化每台 WUs 设备的数据价值，避免传统方案仅以硬件能力评判优先级的局限，为下层博弈提供价值基准；二是设计“三维选择权重”机制，紧扣 CC 全局决策层职能，由 CC 智能体输出 “数据多样性、数据量、设备能量” 权重参数，指导 CHs 结合簇内设备数据价值与硬件状态，动态计算设备综合得分筛选核心参与设备，确保高价值数据设备能参与下层博弈，保障数据价值输入；三是建立“贡献-激励”动态反馈机制，将每轮训练中设备的实际数据贡献（如模型精度提升贡献度）作为调整下一轮激励系数的依据，使上层博弈的激励分配能精准匹配数据价值，充分激发高价值设备参与意愿，既提升数据价值利用率，也通过高质量数据输入改善全局模型泛化性，形成“价值评估-参与筛选-激励反馈”的闭环，贴合 DynaPart-HFL“数据价值驱动三层博弈”的核心设计。

- **动态场景策略适配能力薄弱，系统鲁棒性不足问题**

传统方案在动态环境中普遍存在“策略僵化”问题：契约型机制受限于固定条款或严苛的重协商条件，无法快速响应设备突发故障，如断电、网络中断；拍卖型机制依赖静态数据质量假设，难以适配非独立同分布（Non-IID）数据动态变化与信道干扰；博弈型机制[14]多采用静态梯度求解均衡点，无法实时跟进设备状态变化。多数方案未充分发挥 MADRL 的动态优化能力，或仅通过单智能体调整局部策略，缺乏多智能体间的实时交互与协同适配，导致系统在动态场景中训练连续性难以保障，鲁棒性难以满足实际需求。为解决这一问题，DynaPart-HFL 基于“机制融合+全局状态感知”框架，从**机制**

融合与策略动态化双维度突破。一方面，紧扣三层博弈架构融合契约、拍卖、博弈三类机制优势：CC 与 CHs 间通过“可调整契约”构建上层博弈规则，明确激励分配约束，允许 CHs 在全局框架下根据簇内状态灵活调整子契约，适配上层博弈动态需求；CHs 与 WUs 间通过“分层拍卖”构建下层博弈定价机制，CHs 动态调整拍卖底价，WUs 基于实时成本与数据价值动态报价，实现簇内博弈的高效匹配；同时，通过博弈机制平衡 “激励成本”与“参与质量”，避免单一机制的局限性，形成“**契约约束-拍卖定价-博弈均衡**”的三层机制融合体系。另一方面，依托共享价值网络（Centralized Critic）实现全局状态实时感知，整合 CC 的全局模型精度、CHs 的簇内设备状态、WUs 的本地执行反馈，通过经验回放复用历史数据动态优化策略参数，确保三层博弈策略能实时适配动态环境变化，显著提升系统鲁棒性。

1.3 应用前景

随着 5G/6G 通信、边缘计算和分布式人工智能技术的深度融合，一个由海量异构设备互联协作的“万物智联”时代正加速到来。在这一宏大背景下，分层联邦学习已成为在智能交通、智慧医疗、工业物联网等关键领域实现大规模、隐私保护的协同智能[15]的核心技术。然而，面对这些场景中高度动态的环境、复杂的设备异构性以及参与者的自利行为，传统的基于静态规则或简化模型的参与者选择与激励机制，往往面临着**决策延迟高、适应性差和系统总效用低**等问题。因此，本研究提出的 **DynaPart-HFL 框架**，通过将三层斯塔克伯博弈与多智能体深度强化学习进行深度融合，具有广阔且深远的应用前景。

通过引入**三层斯塔克伯格博弈模型**和基于 **MAPPO** 的**多智能体强化学习求解框架**，本研究不仅能够解决 HFL 系统中多层级、多利益主体下的复杂建模难题，还能够显著提升决策机制的**动态自适应能力**和**优化性能**。三层博弈模型的构建为刻画 HFL“云-边-端”架构下复杂的嵌套激励与决策依赖关系提供了坚实的理论基础，使得系统设计更贴近现实。而基于 MAPPO 的 MARL 求解范式，通过“中心化训练、去中心化执行”，使得系统能够在无需精确环境模型的情况下，通过与环境的直接交互学习出近似的动态均衡策略。这种数据驱动的学习能力，使得我们的框架能够在面对不断变化的网络状况和设备状态时，做出近乎实时的、高效的响应。

在实际应用中，这种将深刻的博弈论[16][17]思想与强大的强化学习工具相结合的 DynaPart-HFL 框架，能够广泛赋能于多个前沿场景，如：**空地协同的灾难应急救援**。

在该场景中，**应急指挥云中心**作为顶层决策者，需在通信基础设施受损且资源极度受限的条件下，协同调度**空中无人机集群**（中间层簇头）与**地面搜救机器人及穿戴设备**（底层工作单元）。面对灾区环境，DynaPart-HFL 框架能发挥关键作用：它使得云中心能够根据救援阶段，如搜救期的时效性优先或重建期的精度优先，动态调整全局激励权重；引导作为边缘节点的无人机利用博弈策略，智能筛选出当前视域数据熵值高且剩余电量充足的地面设备加入训练，自动剔除低质量节点。这种机制在有效延长救援网络生存周期的同时，显著加速了“幸存者目标检测”或“灾情损毁评估”等关键 AI 模型的分布式收敛，从而在黄金救援时间内实现精准的态势感知。此外 DynaPart-HFL 框架因其基于学习的自适应性而具有较强的鲁棒性，能够为大规模分布式智能系统的稳定、高效运行提供可靠保障。

二、研究目标与内容

2.1 研究目标

本研究的核心目标是构建一个名为 **DynaPart-HFL** 的创新框架，通过将三层斯塔克伯格博弈与基于 MAPPO 的多智能体深度强化学习进行融合，以解决分层联邦学习中动态参与者选择与激励设计的联合优化难题。具体来说，我们旨在设计一个能够让 HFL 系统自主学习出近似斯塔克伯格均衡策略的智能决策系统。该系统能够在一个由海量异构设备构成的、动态变化的环境中，协同优化参与者选择策略与多层级激励分配，从而在保障各方利益的同时，最大化全局模型的性能和整个系统的社会总福利。具体子目标如下：

➢构建面向 HFL 架构的三层斯塔克伯格博弈模型

针对传统扁平化博弈模型无法准确刻画 HFL 系统中“云-边-端”层级依赖与先后决策顺序的局限性，本研究旨在**构建一个三层的斯塔克伯格博弈模型**。我们将精确定义各层实体的博弈角色：云中心作为顶层领导者，簇头作为承上启下的中间层，工作设备作为底层跟随者。通过形式化这种非对称的决策依赖关系，本研究致力于在理论层面理清激励策略从云端到边缘再到终端的级联传导机制，为后续的策略优化提供贴近现实的数学模型基础。

➢设计面向多维动态权衡的智能参与者选择机制

为了克服传统选择机制仅依赖单一指标或静态规则[18]的不足，本研究旨在**设计一个动态参与者选择机制**。该机制将中心协调者的决策动作建模为对**数据多样性（泛化能力）、数据量（收敛速度）与设备能量（系统稳定性）**这三个关键指标的权重分配问题。目标是使系统能够根据联邦学习的不同训练阶段，如初期快速收敛、后期提升精度及当前网络状态，自适应地调整选择权重向量，从而实现从“固定规则筛选”到“动态情境适配”的策略转变。

➢构建基于 MAPPO 的博弈均衡寻优算法与 MDP 建模

针对构建的三层斯塔克伯格博弈模型在动态网络环境及不完全信息条件下难以通过传统解析方法求得纳什均衡的挑战[19]，本研究旨在设计一套**基于 MAPPO 的博弈求解方案**。本部分的**核心研究内容在于将复杂的 HFL 博弈问题转化为可求解的多智能体马尔可夫决策过程**。具体而言，我们将重新定义智能体的交互模型：首先，针对云、边、端三层异构实体，设计定制化的**状态空间**与**动作空间**，

解决连续与离散动作混合的控制难题；其次，设计**基于博弈效用的奖励函数**，将斯塔克伯格博弈中的个体效用函数转化为强化学习的即时奖励，引导智能体在追求个体利益最大化的同时逼近系统的纳什均衡点。此外，本研究将针对 HFL 的隐私约束，对 MAPPO 的“集中训练、去中心化执行”范式进行场景化适配：在云端利用全局状态信息训练价值网络以缓解环境非平稳性，而在边缘侧仅部署动作网络，使其仅凭本地局部观测即可做出决策，从而在实现自适应优化的同时，严格保障各参与方的数据隐私与通信效率。

2.2 研究内容

本论文基于**分层联邦学习**、**斯塔克伯格博弈论**以及**多智能体深度强化学习**相关理论与技术，针对 HFL 环境下“云-边-端”三层架构中的动态参与者选择与激励机制设计问题开展一系列研究，旨在提升 HFL 系统的整体性能与经济效率。论文开展的主要研究内容包括：构建面向 HFL 的三层斯塔克伯格博弈模型、设计基于 MAPPO 的多智能体强化学习求解框架，以及设计面向多维动态权衡的智能参与者选择机制等三个方面。现对上述研究内容进行详细阐述：

➢**构建面向 HFL 的三层斯塔克伯格博弈模型**：在分层联邦学习系统中，各参与方的决策存在明确的先后顺序和层级依赖，这使得传统的扁平化博弈模型[20]难以准确刻画其内部复杂的经济关系。为了有效应对这一挑战，本研究引入了**三层斯塔克伯格博弈**来进行系统建模。传统的多智能体系统模型往往假设所有智能体在同一层级进行同步或异步决策，忽略了 HFL 架构中天然存在的**领导者-跟随者**结构。例如，中心协调者的激励和选择策略会直接影响下层集簇头的资源竞标策略，而 CHs 的竞标结果又会决定底层工作设备是否愿意参与。这种嵌套的、非对称的决策依赖关系，正是斯塔克伯格博弈的核心特征。本研究将精确地形式化这个三层博弈：定义 CC 为顶层领导者，其策略：如**动态选择权重**和激励预算为最高层决策；定义 CHs 为中层参与者，它们作为 CC 的跟随者，同时又是 WUs 的领导者，其策略：如单位数据出价，承上启下；定义 WUs 为底层跟随者，其策略：是否参与，是对上层激励的最终响应。通过构建这一高保真度的博弈模型，我们能够为后续的强化学习求解提供一个清晰、严谨、贴近现实的理论框架。

➢**设计面向多维动态权衡的智能参与者选择机制**：在 HFL 系统中，如何选择参与者是一个复杂的、多目标的决策问题。传统的选择机制往往采用固定的、单

一维度的标准，这种静态策略无法适应联邦学习长期训练过程中的动态需求变化。为了解决这一局限性，本研究的核心创新之一在于设计一个**具备动态多维权衡能力的智能参与者选择机制**。具体而言，我们将云中心智能体的动作空间设计为一个能够输出策略权重向量的结构。该向量直接控制着选择标准中对三个关键维度的重视程度：**1、数据多样性**:衡量设备数据能否为全局模型带来新的知识，有助于模型跳出局部最优、提升泛化能力。**2、数据量**:保证模型训练的稳定性和收敛速度。**3、设备能量**:确保系统的可持续性，避免过度消耗低能量设备的资源。

➢**设计基于 MAPPO 的多智能体强化学习求解框架**：在构建了复杂的三层博弈模型后，传统的解析求解方法因其对环境模型的苛刻假设（如效用函数凸性、完美信息）而不再适用。为了在模型未知、动态变化的环境中找到近似的均衡策略，本研究引入了**基于 MAPPO 的多智能体强化学习算法**作为核心求解引擎。MAPPO 的核心优势在于其“中心化训练、去中心化执行”的 CTDE 范式[21]。在 HFL 这个分布式系统中，CTDE 范式具有天然的契合性：

1、中心化训练：在训练阶段，我们利用一个**共享的全局 Critic 网络**，它可以访问到所有智能体的联合观测和动作信息。这使得 Critic 能够从一个全局的视角准确评估当前系统状态的价值以及联合策略的优劣，从而为每个智能体的学习提供一个全局一致的指导信号，有效解决了多智能体环境中的非平稳性问题。

2、去中心化执行：在决策阶段，每个智能体的 **Actor 网络**仅根据其自身的局部观测信息来独立做出决策。这完全符合 HFL 系统的物理约束，即中心服务器无法知晓所有终端设备的实时私有状态。

通过这一框架，我们将实现一个“云-边-端”的学习流程，让三层智能体的策略在相互博弈中协同进化，最终收敛到一个高效的近似斯塔克伯格均衡。

CC 智能体将通过强化学习[22]，学会根据当前的系统状态（如全局模型准确率、训练阶段、备选池设备状态等）自主地、动态地调整这个权重向量。例如，在训练初期，智能体可能会学习到提高对“数据量”的权重以加速收敛；而在训练后期模型性能陷入瓶颈时，它可能会转而提高对“数据多样性”的权重，以寻找新的优化方向。这种情境感知的动态权衡能力，是本研究机制“智能”的核心体现，旨在让参与者选择策略从静态的“规则”进化为动态的“智慧”。

三、拟采取的研究方法、技术路线、实验方案及可行性分析

3.1 研究方法及技术路线

（1）分层联邦学习模型

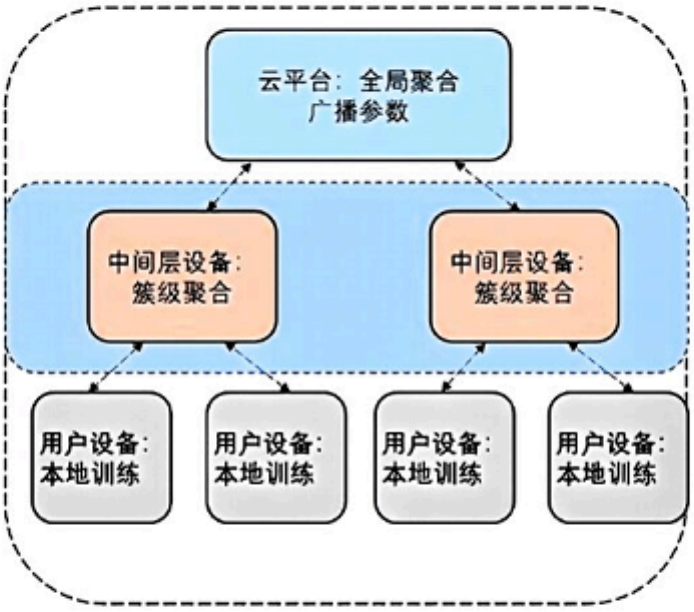


图 2 分层联邦学习模型图

构建分层联邦学习模型，以“云中心（CC）-簇头（CHs）”“簇头（CHs-工作单元（WUs）”为两级核心交互分层，CHs 作为关键中间节点，串联全局决策与本地执行，形成 “全局统筹-簇内协调-本地落地” 的递进式协同体系[23]，各层级交互逻辑与职能明确。

第一层：云中心-簇头：全局决策与簇内承接的交互层

云中心：全局决策发起者，负责制定覆盖所有簇的全局策略包括：参与者选择的三维权重（数据多样性、数据量、设备能量）、跨簇资源调配规则：接收各 CHs 上传 的簇级聚合模型与簇内状态，通过全局加权聚合生成最终全局模型；

簇头：全局策略承接者，接收云中心的全局策略后，转化为簇内适配方案：根据 全局选择权重调整簇内设备筛选标准（如侧重高数据多样性或低能耗设备）；聚合簇内工作单元的本地模型，生成簇级模型并上传至 云中心；向云中心反馈簇内关键状态，如设备离线率、数据 Non-IID 程度辅助云中心优化下一轮全局策略。

第二层：簇头-工作单元：簇内协调与本地执行的交互层

簇头：簇内协调主导者，向簇内工作单元下发适配后的簇级方案：明确本地

训练任务（如训练轮次）、设定模型上传时限；接收工作单元上传的本地训练模型与本地状态，如自身剩余能量、数据样 本量、参与意愿。

工作单元：本地执行落地者，接收簇头下发的簇内方案，基于本地数据集完成训练：加载簇头转发的初始模型，模型更新参数由云中心广播，通过最小化损失函数生成本地模型参数并上传至簇头；向簇头实时反馈本地状态，如训练过程中的能耗变化、数据类别分布。

系统架构

➢定义实体：一个云中心（Cloud Center，CC）、一个由N个簇组成的集合$\mathcal{N}=\{1,2,\ldots,N\}$、每个$n\in\mathcal{N}$包含 M 个工作设备角色、一个由K个备选客户端设备组成的备选池$\mathcal{K}=\{1,2,\ldots,K\}$

分层联邦学习数学建模：

➢设备本地训练：

对于工作组 $\mathcal{W}$ 中的每个设备$k\in\mathcal{W}$，它拥有本地数据集$\mathcal{D}_k$，它接收从其所属簇n广播下来的模型参数w_n设备k通过在其本地数据上最小化损失函数来更新模型，得到新的本地模型$w_k{}'$：

$w_k{}'=arg\min_{w}\sum_{(x_j,y_j)\in\mathcal{D}_k}L\left(f(x_j;w),y_j\right)$（编号）

其中 L 是损失函数，f是神经网络模型。

➢簇级聚合：

簇头n收集其管辖的所有工作设备$k\in\mathcal{W}_n$上传模型$w_k{}'$，它通过加权平均聚合这些模型，得到更新后的簇模型$w_n{}'$：

$$w_n{}'=\frac{\sum_{k\in\mathcal{W}_n}|\mathcal{D}_n|\cdot w_k{}'}{\sum_{n\in\mathcal{W}_n}|\mathcal{D}_n|}$$

➢全局聚合：

云中心收集所有簇$n\in\mathcal{N}$上传的簇模型$w_n{}'$，然后云中心通过加权平均聚合这些簇模型，得到更新后的全局模型W'

$$W'=\frac{\sum_{n\in\mathcal{N}}|\mathcal{D}_n|\cdot w_n{}'}{\sum_{n\in\mathcal{N}}|\mathcal{D}_n|}$$

其中$|\mathcal{D}_n| = \sum_{k \in \mathcal{W}_n} |\mathcal{D}_k|$是簇$n$的总数据量。

能量消耗模型：

➢通信消耗[24]：设备k上传模型会产生通信成本。可以将其建模为与设备k的能量E_k和参与意愿p_k相关，通信能耗可以表示为：

$$E_{comm,k} = C_{comm} \cdot p_k$$

其中C_{comm}是一个常数系数。

➢工作单元能耗：设备k的能耗分为计算能耗和通信能耗，计算能耗为$E_{k,compute} = P_{cpu} \cdot \frac{c_k \cdot |\mathcal{D}_k|}{f_k}$，其中$P_{cpu}$为计算功耗，$c_k$为每个样本计算周期，$f_k$为设备算力。所以工作单元总能耗为：

$$E_k^{total} = E_{k,compute} + E_{k,comm}$$

➢簇头无人机能耗[25]：无人机 n 能耗包括飞行能耗、计算能耗和通信能耗。飞行能耗公式为$En, flight = P_f \cdot t$, 其中P_f为飞行功率，t 为飞行时间；计算能耗公式为$E_{n,compute} = P_{cpu,n} \cdot \frac{\mathrm{Cn}}{\mathrm{F_n}}$，其中$P_{cpu,n}$为无人机计算功耗，$C_n$为簇内聚合计算量，$F_n$为无人机算力。所以簇头无人机总能耗为：

$$E_n^{total} = E_{n,fligt} + E_{n,compute} + E_{n,comm}$$

（2）Stackelberg 博弈模型构

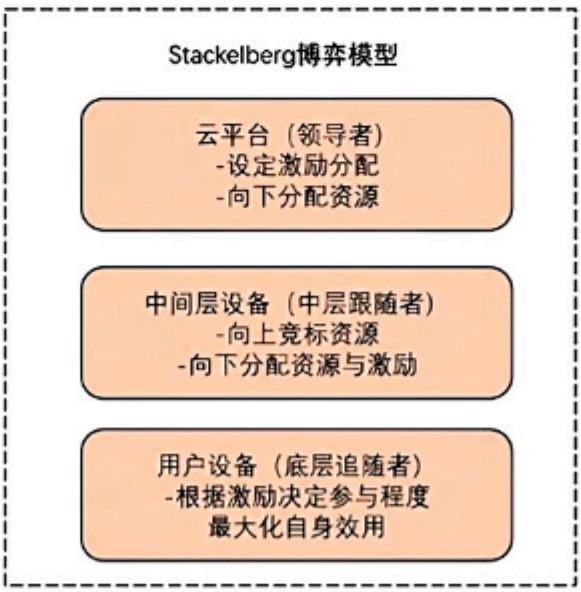


图 3 Stackelberg 博弈模型

构建三层 Stackelberg 博弈模型，云平台作为领导者，负责设定激励分配和资源分配；中间层设备作为中间层追随者，**根据云平台策略，以最小成本，资源最大化，向下分配资源与激励；用户设备作为底层追随者，根据激励决定设备参与程度，同时最大化自身效用。**

➢策略定义：

云平台的策略：$a_{CC} = \{I, R, C, S\}$：激励分配为$I = \{i_1, \dots, i_N\}$，其中$i_n \in [0,1]$是分配给簇n的激励率；资源分配为$R = \{r_1, \dots, r_N\}$，其中$r_n \in \mathbb{R}^+$是分配的资源量；协作矩阵C是一个$N \times N$的矩阵其中$c_{nm} \in [0,1]$；选择权重为$S = \{s_{diversity}, s_{quantity}, s_{energy}\}$，分别代表对数据多样性，数据量和能量偏好。

簇头n的策略：$a_n = \{b_n, Q_n\}$：竞价价格$b_n \in [0,1]$；协作请求Q_n是一个$1 \times N$的向量，其中$q_{nm} \in [0,1]$是对簇 m 的协作请求。

设备k的策略$a_k = \{p_k\}$：参与意愿$p_k \in [0,1]$

➢博弈模型中的效用函数：

云平台的目标，通过设定策略$a_{CC} = \{I, R, C, S\}$最大化自身效用U_{CC}，即：

$$U_{CC} = G_{acc}(W') + G_{div}(S) - C_{res}(R) - C_{inc}(I) - C_{cov}(C, M_{diff})$$

其中精度收益为$G_{acc}(W')$，多样性收益为$G_{div}(S)$，资源成本为$C_{res}(R)$，激励成本为$C_{inc}(I)$，协作成本为$C_{cov}(C, M_{diff})$

簇头n的目标，在云中心的全局约束下，最大化簇对全局模型的贡献收益，同时最小化自身竞价成本与协作成本，实现“簇级贡献-自身成本”的局部最优，定义为：

$$U_{CH_n} = G_{global}(W', S) - C_{bid}(b_n) - C_{req}(Q_n)$$

其中$G_{global}(W', S)$为精度收益，$C_{bid}(b_n)$为竞标成本，$C_{req}(Q_n)$为协作成本

设备k的目标，在簇头的簇内约束下，最大化本地参与的激励收益，同时最小化自身参与的能耗成本，实现“个体收益-参与成本”的局部最优，即：

$$U_{WU_k} = G_{local}(i_n, p_k, d_k) - C_{part}(p_k)$$

其中$G_{local}(i_n, p_k, d_k)$为设备收益，$C_{part}(p_k)$为设备能耗。

（3）分层强化学习框架（HG-MAPPO）

在三层 Stackelberg 博弈的基础上，通过 HG-MAPPO 实现分层策略的动态协同优化。该框架将全局决策、簇内协调与本地执行的策略分解为独立子策略，通过多智能体强化学习逐层优化[26]，最终达成系统全局目标。具体而言，HG-MAPPO 包含云中心、簇头和工作单元，分别负责全局资源与激励分配、簇内策略适配及本地参与决策的优化任务。

云中心作为顶层决策者，负责全局资源配额与激励预算的分配策略优化，其核心目标是通过动态调整三维选择权重：数据多样性、数据量、设备能量和跨簇协作规则，最大化系统长期效用。云中心代理的决策结果将作为中层代理的输入约束，引导簇内策略的适配方向。此层的优化目标函数为：

$$\max_{a_{CC}} \mathbb{E}[U_{CC}(a_{CC}, \{a_n^*\}, \{a_k^*\})]$$

簇头作为中层协调者，负责云中心的全局策略拆解为簇内可执行方案，包括子激励分配、设备筛选与簇内模型聚合规则的优化。该层通过感知簇内设备的实时状态：剩余能量、数据价值、参与意愿，动态调整拍卖底价与契约条款[27]，目标是在全局约束下最大化簇级短期效用。簇头代理的优化目标函数为：

$$\max_{a_n} \mathbb{E}\left[U_{CH_n}(a_{CC}, a_n, \{a_n^*\}, \{a_k^*\})\right]$$

工作单元作为底层执行者，负责根据 簇头 的簇内策略调整本地参与意愿与训练投入度，核心目标是在自身能耗成本约束下，通过优化参与策略最大化个体收益。该层通过反馈本地训练状态，如模型精度、数据贡献度，为上层策略调整提供依据，其优化目标函数为：

$$\max_{a_k} \mathbb{E}\left[U_{WU_k}(a_{CC}, \{a_n^*\}, a_k)\right] \quad \forall k \in \mathcal{K}$$

利用 HG-MAPPO 机制优化协同策略

在多层级智能体交互场景中，传统 MAPPO 因缺乏对“领导者-跟随者”博弈关系的适配，难以处理策略耦合与利益冲突问题。HG-MAPPO 通过定制化改进，实现分层策略的高效协同优化。

层级化策略网络：为 CC、CHs、WUs 设计独立策略网络，分别适配全局决策的长周期规划、簇内协调的中周期调整、本地执行的短周期响应需求，网络输入包含各层级专属状态特征。

博弈感知奖励机制：将三层效用函数直接作为各代理的奖励信号，使 CC 的策略优化体现全局统筹、CHs 的策略优化反映簇内均衡、WUs 的策略优化聚焦个体收益，通过奖励耦合实现“全局最优-局部响应”的动态平衡。

经验回放与分层更新：引入跨层级经验池存储 CC、CHs、WUs 的交互数据，利用 MAPPO 的近邻策略优化特性，在保证策略更新稳定性的同时，允许各层级基于历史数据迭代，大幅提升大规模设备场景下的学习效率。

通过这种分层优化机制，HG-MAPPO 能够在设备异构、数据动态变化的环境中快速收敛至近似斯塔伯格均衡，既解决了传统强化学习对层级博弈适配不足的问题，又通过定制化状态与奖励设计，确保策略优化与联邦学习的训练流程、资源约束深度耦合，最终实现系统精度、能耗与参与度的多目标优化。

3.3 实验方案

（1）实验流程

实验流程分为两个核心阶段：首先通过分层联邦学习（HFL）完成分布式模型训练，然后基于 HG-MAPPO 算法优化三层智能体的协同策略，最终实现 “模型精度-资源成本-参与均衡”的多目标优化。

分层联邦学习训练：在该阶段，系统按 “工作单元（WUs）→簇头（CHs）→云中心（CC）” 的层级完成模型迭代：首先，工作单元从备选池中被筛选后，加载簇头下发的初始模型，利用本地数据集进行训练，生成局部模型参数并上传至所属簇头，然后簇头接收簇内所有的局部模型，通过 FegAvg 算法[28]聚合得到簇模型参数，并将簇模型参数与簇内状态同步至云中心，最后云中心聚合所有簇头上传的簇模型参数，生成全局模型，并计算本轮模型精度提升，作为下一轮策略优化的基础。

HG-MAPPO 策略优化：在联邦学习每轮训练结束后，基于当前全局模型精度、设备状态及资源消耗数据，通过 HG-MAPPO 训练三层智能体策略。先由云中心代理根据全局状态调整资源分配、激励预算以及参与者选择权重。其次簇头代理根据云中心的策略与簇内状态，优化竞价与子激励分配，之后工作单元代理根据簇头的子激励规则，调整参与意愿。最后系统通过计算各层效用，HG-MAPPO 的策略网络迭代，直至收敛至稳定策略。

（2）使用以下评价指标评估实验结果：

模型准确率：通过全局模型在测试集上的分类准确率评估联邦学习效果：

$$Acc(W') = \frac{1}{|\mathcal{D}_{test}|} \sum_{(x,y)\in\mathcal{D}_{test}} \mathbb{I}(f(x;W') = y)$$

系统总效用：系统的总效用评估了 激励机制的总体效果，反映了定价策略对各层学习的激励效果，总效用公式为：

$$Utotal = Gacc(W') + Gdiv(S) - Cres(R) - Cinc(I) - Ccov(C, Mdiff)$$

设备参与均衡性：通过各工作单元的参与频率标准差衡量策略公平性，公式为：

$$(\sigma_p = \sqrt{\frac{1}{K}\sum_{k=1}^{K}(p_k - \bar{p})^2})$$

其中$\bar{p}$为平均参与意愿，反映策略对设备积极性的平衡效果。

（3）实验参数设置

实验中选取三种典型数据集（如 MNIST、Fashion-MNIST 和 CIFAR-10）来评估算法在不同任务中的表现。不同数据集使用不同的模型和超参数设置。例如，针对 MNIST 数据集，使用两层卷积神经网络模型，batch 大小为 64，每轮训练中各节点的 epoch 数设置为 20。对于 CIFAR-10 数据集，则使用更深的卷积神经网络（如 CNN）模型，batch 大小相同，epoch 数为 25。

三、拟采取的研究方法、技术路线、实验方案及可行性分析

3.4 可行性分析

（一）技术可行性

分层联邦学习（HFL）、斯塔克伯格博弈（Stackelberg Game）和多智能体深度强化学习（MADRL）的研究均有大量相关文献支持，并且已经在分布式系统、无线通信和边缘计算领域得到了广泛的应用与验证，具有扎实的理论基础和明确的实践意义。此外，本研究采用的 MAPPO 算法作为 PPO 算法在多智能体领域的直接扩展，继承了其优异的收敛稳定性和样本效率，其“中心化训练、去中心化执行”的范式是解决多智能体协调博弈问题的成熟方案。这一优化方法依赖于成熟的深度学习框架（如 PyTorch）和强化学习库实现，能够充分满足我们对复杂博弈策略进行高效优化的需求。项目中涉及的核心组件，如 Actor-Critic 网络结构、共享经验回放缓冲区等，均有标准化的实现范式。最为关键的是，本课题的核心代码框架，包括 HFL 环境模拟器和 MAPPO 训练引擎，均已开发完成并初步调试通过，为后续研究的顺利开展提供了充分的技术支持。

（二）实验可行性

本研究采用了业界广泛应用的图像分类真实数据集（如 MNIST 和 CIFAR-10），并通过我们自行设计的结构化异构数据生成脚本，能够高保真度地模拟分层联邦学习场景下设备异构、数据 Non-IID 的核心挑战。实验流程清晰合理，严格遵循“环境搭建->基准实现->模型训练->性能评估-> 机制分析”五个阶段。通过合理设计包括全局模型准确率、系统总效用（社会福利）、收敛速度以 CC 智能体策略权重演化在内的多维度评价指标，能够对我们提出 DynaPart-HFL 框架进行全面、深入的评估。此外，实验过程中将采用标准化的超参数配置，并设置多种基准算法（如随机选择、贪婪策略）进行严格的对比实验，以保证研究结果的科学性和可复现性。这些设计表明，本研究在技术实现和实验验证方面均具备较强的可操作性和可靠性，能够为 HFL 系统中的动态参与者选择与激励设计问题提供有效的、可信的解决方案。

四、研究(设计)计划及时间安排

时间	研究工作	预期成果
2024.09-2025.11	文献调研、确定选题	形成深度强化学习深入了解
2025.11	开题答辩	完成开题答辩
2025.12-2026.04	完成相关数据的采集与预处理，研究相关领域算法，初步完成实验	建立实验相关数据集，初步完成关键算法实验，投稿论文
2026.04-2026.08	优化相关算法，完成对比实验，并撰写论文	优化算法；撰写论文
2026.09-2026.10	中期答辩	完成中期答辩
2026.10-2027.04	分析总结实验，撰写毕业论文	完成毕业论文的撰写
2027.04-2027.05	论文审查与论文答辩	完成论文答辩

主要参考文献

[1] YUAN X M, CHEN J H, ZHANG N, et al. Low-cost federated broad learning for privacy-preserved knowledge sharing in the RIS-aided Internet of Vehicles[J]. Engineering, 2024, 33: 178-189.

[2] HONG Q Y, MENG F L, LIU J, et al. A bilevel game-theoretic decision-making framework for strategic retailers in both local and wholesale electricity markets[J]. Applied Energy, 2023, 330: 120311. .

[3] Manek G, Pappas G J, Jadbabaie A. Distributed policy optimization for scalable control of networked systems[J]. Nature Machine Intelligence, 2024, 6(12): 1121 - 1132.

[4] Zhu Y, Zhang Y. A game-theoretic cooperative path planning strategy using hybrid heuristic optimization algorithm[J]. IET Control Theory & Applications, 2024, 18(18): 2742 - 2754.

[5] MA B, FENG Z, GAO Y, et al. Secure service-oriented contract based incentive mechanism design in federated learning via deep reinforcement learning[C]//2024 IEEE International Conference on Web Services (ICWS). Shenzhen, China: IEEE, 2024: 535-544.

[6] 郭英芸,高博,卢宇平,张煜,熊轲.一种基于反向多维拍卖模型的联邦学习激励机制[J].新型工业化,2022,12(5):236-244.

[7] LIU Y, CHANG S, LIU Y, et al. FairFed: Improving fairness and efficiency of contribution evaluation in federated learning via cooperative Shapley value [C]//IEEE INFOCOM 2024 - IEEE Conference on Computer Communications. Vancouver, BC, Canada: IEEE, 2024: 621-630.

[8] TAN X, TANG X L, HAN Y. A renegotiable contract-theoretic incentive mechanism for federated learning[EB/OL]. 2025.

[9] KANORIA Y, NAZERZADEH H. Dynamic reserve prices for repeated auctions: learning from bids[C]//LIU T Y, QI Q, YE Y. Web and Internet Economics. Cham: Springer International Publishing, 2014: 232-232.

[10] MOUSAVI S, SCHUKAT M, HOWLEY E. Deep reinforcement learning: an overview[C]//Proceedings of SAI Intelligent Systems Conference 2016: Volume 2. Cham: Springer International Publishing, 2018: 426-440

[11] 李秋贤,周全兴.非独立同分布数据环境下的联邦学习激励机制设计[J].现代信息科技,2024,8(22):30-35.

[12] 谢 陶 ，黄迎春 . 基于深度强化学习的边缘计算资源分配方法 [J]. 火力与指挥控制,2024,49(09):185-190

[13] LIU Y, GUO S, ZHAN Y, et al. Chiron: A robustness-aware incentive scheme for edge learning via hierarchical reinforcement learning [J]. IEEE Transactions on Mobile Computing, 2024.

[14] SHI D, LI L, OHTSUKI T, et al. Make smart decisions faster: Deciding D2D resource allocation via stackelberg game guided multi-agent deep reinforcement learning [J]. IEEE Transactions on Mobile Computing, 2021, 21 (12): 4426-4438.

[15] 沈熠能.基于边缘计算的多智能体通信技术研究[D].浙江大学,2023.

[16] 王辉,夏玉琦,李欣,等.基于多主体三层博弈的区域综合能源系统低碳运行策略[J].中国电力,2025,58(08):69-83.

[17] QIANG X K, CHANG Z, MIN G Y. AIGC-assisted federated learning for vehicular edge intelligence: Vehicle selection, resource allocation and model augmentation [J]. IEEE Transactions on Mobile Computing, 2025, 24 (11): 11896-11909.

[18] 王童,李鹜,宋海荦,等.基于分层深度强化学习的移动机器人导航方法[J].控制与决

策,2022,37(11):2799-2807.
[19] 陈娟,钟杰,吴宗玲,等.星地协同中基于多智能体的时敏任务调度优化策略[J].物联网学报,1-16[2025-11-13].
[20] 张建东,王鼎涵,杨啟明,等.基于分层强化学习的无人机空战多维决策[J].兵工学报,2023,44(06):1547-1563.
[21] 全韩彧,钱彦屹,田晖,等.SDFL:一种隐私保护和拜占庭鲁棒的去中心化联邦学习方案[J].中国科学:信息科学,2025,55(11):2645-2662.
[22] MOUSAVI S S, SCHUKAT M, HOWLEY E. Deep reinforcement learning: an overview [C]//Proceedings of SAI Intelligent Systems Conference 2016: Volume 2. Cham: Springer International Publishing, 2018: 426-440.
[23] LIU Y, GUO S, ZHAN Y, et al. Chiron: A robustness-aware incentive scheme for edge learning via hierarchical reinforcement learning [J]. IEEE Transactions on Mobile Computing, 2024.
[24] 黄有德,赵雪丹,郭艺,等.无线通信的能耗优化策略研究[J].智能物联技术,2025,57(04):96-100.
[25] 邓健，张洪海，华明壮，等. MODDPG–NSGA2 双层架构：面向动态场景的物流无人机多目标优化方法 [J]. 工程科学学报，2025 [2025-11-13].
[26] 畅鑫,李艳斌,刘东辉.基于分层强化学习的多智能体博弈策略生成方法[J].无线电工程,2024,54(06):1361-1367.
[27] KANORIA Y, NAZERZADEH H. Dynamic reserve prices for repeated auctions: Learning from bids [C]//LIU T Y, QI Q, YE Y. Web and Internet Economics. Cham: Springer International Publishing, 2014: 232-232.
[28] 葛佳琦.面向非独立同分布数据的个性化联邦学习模型聚合方法研究[D].吉林大学,2025.

导师意见(专硕需双导师签名)

同意开题！

指导教师签名：

行业导师签名(专硕)：熊科

2025年 11月 27日

开题评审小组意见

组长签名：

11 28

所在学院学术分委会意见

同意

学术委员会主任签名：

肥大 人工智能与大数据学院

年 月 日